

Enseignement d'Intégration

Victor Roussel, Lucie Huang, Clarisse Vitet, Elina Bouinot, Timothée Bénézit

27 juillet 2026

Projet EI Henri Mondor, Séquence Thématique 4 : Big Data et Santé

1 Introduction

L'objectif de ce projet est d'améliorer le diagnostic du cancer du foie en utilisant l'analyse de données radiomiques issues d'imagerie médicale. Parmi les divers types de cancers hépatiques rencontrés, deux formes principales prédominent : le carcinome hépatocellulaire (CHC), représentant environ 80 % des cas, et le cholangiocarcinome (CCK). De nombreux patients souffrent simultanément de ces deux types de cancer, rendant le diagnostic particulièrement complexe.

Ces formes de cancer nécessitent des traitements distincts. Or, le diagnostic est souvent posé à un stade tardif de la maladie, principalement en raison d'une symptomatologie peu spécifique. Il est donc crucial d'obtenir rapidement un diagnostic fiable, quant au type précis de cancer du foie. Fort heureusement, ce cancer peut être détecté par diverses méthodes, incluant les analyses sanguines, mais surtout grâce à l'imagerie médicale, notamment par IRM.

Toutefois, l'analyse détaillée des images médicales et des données radiomiques associées demande beaucoup de temps. Le défi de ce projet est donc de réduire cette tâche chronophage pour permettre aux médecins de prendre en charge davantage de patients.

Ainsi, nous nous concentrerons sur l'identification des variables radiomiques les plus déterminantes pour distinguer efficacement le CHC du CCK chez les patients.

2 Données et Problématique

Nous avons le dataset Radiomiques-global à disposition. Ce document contient la synthèse de l'ensemble des informations radiomiques relatives aux images obtenues lors d'IRM après injection d'un produit de contraste : forme, couleur, texture, etc. Elles sont obtenues à 4 phases différentes : artérielle (ART), portale (PORT), veineuse (VEIN) et tardive (TARD), et certaines phases peuvent manquer pour certains patients dans ce dataset.

En tout, 147 patients sont suivis ici :

- 87 avec un cancer CHC - 23 avec un cancer CCK - 37 avec un cancer Mixte

Dans la suite de l'analyse, seuls les deux premiers groupes seront pris en compte.

L'objectif est donc de déterminer les variables les plus influentes lors du diagnostic du patient. La difficulté de l'analyse de données se trouve dans la forte corrélation de nombreuses variables, dans l'absence de données, mais aussi dans la sous-représentation du groupe CCK.

3 Résultats et discussion

Plusieurs méthodes sont abordées par la suite : Multiview, Random Forest et ACP afin de répondre au problème.

3.1 Multiview avec groupLASSO

La régression logistique est une méthode de classification binaire. La méthode multiview permet d’avoir une extension de cette méthode pour plusieurs blocs. A l’aide de celle-ci, nous pouvons considérer des blocs de données selon les différents temps d’injection ART, VEIN, TARD et PORT, ainsi que des blocs de différences entre les variables "first-order" pour VEIN-TARD, VEIN-PORT, ART-VEIN et TARD-ART. Nous avons une pénalisation groupLASSO pour multiview appliquée aux différents blocs.

3.1.1 Traitement des données

Nous avons, tout d’abord, enlevé la classe "Mixtes", qui ne nous sert pas dans notre analyse, et normalisé les données selon leurs classes. Nous avons imputé les données manquantes par la moyenne des variables respectivement à la classe du patient. Puis, nous avons créé un identifiant unique pour chacun des patients afin de regrouper toutes leurs données issues des différents temps d’injection en une ligne unique.

Nous avons également ajouté des poids aux deux classes considérées (fonctionnalité intégrée dans multiview), CHC et CCK, afin de rééquilibrer la classe minoritaire CCK.

3.1.2 Démarche

Nous avons créé une boucle avec 100 "seeds" différents, ce qui nous permet d’avoir des partitionnements distincts des données à chaque itération, et de moyenner les performances.

Au sein de la boucle, nous avons partitionné nos données en 80% pour l’apprentissage et 20% pour le test, en faisant un échantillonnage stratifié (même proportion de CHC et CCK dans les échantillons d’apprentissage et de test).

Nous avons fait une cross-validation avec le modèle multiview pour trouver l’hyperparamètre λ_{opt} du groupLASSO sur les données d’apprentissage. Nous récupérons le modèle optimisé avec λ_{opt} , ainsi que les variables sélectionnées avec leurs coefficients dans le modèle.

Pour avoir les différentes métriques voulues (accuracy, sensibilité, spécificité, AUC, F1-score de la classe minoritaire), nous appliquons ce modèle optimisé aux données de test.

A la fin de la boucle, nous affichons les 40 variables les plus sélectionnées, leur fréquence de sélection, leur coefficients moyens associés, ainsi que les performances moyennes du modèle sur les 100 seeds. Cela nous permet de savoir quelles sont les variables les plus influentes sur le résultat final et ainsi de ne conserver que celles-ci lors de futures analyses.

3.1.3 Résultats

Nous avons premièrement mis les 4 blocs ART, PORT, VEIN, TARD en entrée. Nous choisissons d’afficher les 40 variables les plus fréquemment sélectionnées, ainsi que leurs coefficients moyens sur les 100 seeds distincts.




FIGURE 1 – Sélection de variables sur 100 seeds avec blocs ART, PORT, VEIN et TARD

Voici les performances associées :

	accuracy	sensitivity	specificity	auc	f1_class0
mean	0.780	0.799	0.698	0.839	0.550
sd	0.078	0.095	0.217	0.099	0.136

FIGURE 2 – Performance blocs ART, PORT, VEIN, TARD

En ne considérant que les variables renvoyées par le modèle, nous observons que les performances du modèle sont améliorées :

--- Performances avec top_mv (Multiview) ---

	accuracy	sensitivity	specificity	auc	f1_neg
mean	0.851	0.876	0.745	0.907	0.660
sd	0.079	0.083	0.201	0.080	0.166

FIGURE 3 – Performance top 40 variables sélectionnées avec blocs ART, PORT, VEIN, TARD

Afin de ne pas perdre d'information en considérant les différents blocs séparément, nous choisissons de comparer les variables "first-order", correspondant à l'histogramme des distributions de gris, entre les différentes phases d'injection. Pour cela, nous ajoutons en entrée les blocs VEIN-TARD, VEIN-PORT, ART-VEIN et TARD-ART. Nous choisissons ces blocs car ils sont en théorie ceux qui peuvent nous permettre d'obtenir les meilleurs résultats, ayant les variations les plus importante de niveaux de gris entre deux phases d'injection. Les deux premiers proviennent d'une volonté de comparer les deux phases successives. Tandis que les deux suivants sont issus d'une réflexion autour des variances entre la phases ART (la première phase) et les phases les plus éloignées (TARD et VEIN).

Nous avons choisi de conserver les variables les plus fréquemment sélectionnées communes à l'intersection des variables renvoyées avec seulement les blocs delta et les blocs delta et temps d'injection, et l'intersection des variables renvoyées entre les blocs delta et temps d'injection et les blocs temps d'injection uniquement.

En réentraînant le modèle avec les 20 variables obtenues avec les 8 blocs en entrée, nous obtenons les résultats suivants :




FIGURE 4 – Sélection de variables sur 100 seeds avec blocs ART, PORT, VEIN et TARD et VEIN-TARD, VEIN-PORT, ART-VEIN et TARD-ART

	accuracy	sensitivity	specificity	auc	f1
mean	0.880	0.775	0.904	0.933	0.710
sd	0.066	0.199	0.070	0.067	0.142

FIGURE 5 – Performance top 15 variables avec blocs ART, PORT, VEIN, TARD, VEIN-PORT, ART-VEIN et TARD-ART avec les 20 variables choisies

3.1.4 Interprétation

L'analyse des composantes les plus explicatives de l'approche multiview met en évidence plusieurs éléments importants qui confirment ou complètent les observations cliniques des cancérologues.

Tout d'abord, la phase portale ressort clairement comme étant particulièrement informative pour caractériser les tumeurs dans notre contexte.

Ensuite, il apparaît que les variables obtenues par les différences entre phases successives, en particulier entre les phases portale et artérielle, jouent un rôle déterminant. Cette approche méthodologique est intéressante, car elle permet non seulement de compenser d'éventuelles différences de calibrage entre les équipements IRM utilisés, mais également de faire ressortir les dynamiques spécifiques d'évolution tumorale plutôt que leurs seules valeurs absolues.

Certains des coefficients les plus souvent retenus par notre modèle sont directement interprétables d'un point de vue clinique. Ainsi, un coefficient positif indique que des valeurs élevées de la variable correspondante orientent le diagnostic vers un carcinome hépatocellulaire (CHC), tandis qu'un coefficient négatif favorise plutôt un diagnostic de cholangiocarcinome (CCK).

Selon la figure 2, les variables les plus pertinentes sont la sphéricité observée en phase portale et la différence d'entropie entre les phases veineuse et portale. Ces deux variables présentent des coefficients moyens positifs, confortant ainsi les analyses cliniques selon lesquelles le CHC se caractérise souvent par une forme plus arrondie, et une dynamique d'entropie reflétant la cinétique du produit de contraste.

En particulier, l'association positive de la différence d'entropie entre ces phases suggère que le caractère fibreux du CCK, entraînant une rétention prolongée du produit de contraste, serait moins marqué que dans les cas de CHC.

Enfin, la variable ayant le coefficient négatif le plus marqué correspond à la différence du premier ordre de la médiane entre les phases veineuse et portale. Une augmentation de cette différence traduit une diminution notable d'intensité, cohérente avec une rétention prolongée du produit de contraste, typique du CCK.

Ces observations montrent ainsi comment notre analyse quantitative est en phase avec les observations qualitatives et cliniques des cancérologues, validant l'approche méthodologique adoptée.

3.2 ACP

Dans la deuxième partie nous utilisons la méthode de l'*Analyse des Composantes Principales*. Puisque la complexité et le grand nombre de variables rendent difficile l'interprétation clinique et l'entraînement de modèles prédictifs, la PCA pourrait permettre de simplifier ce problème en réduisant le nombre de dimensions (Figure 6).





FIGURE 6 – Réduction en 2 dimensions de toutes les données par ACP

Ensuite, nous nous sommes restreints aux variables les plus pertinentes de la partie précédente, sélectionnées en normalisant les données, puis en appliquant une approche *Multiview*. (Figure 7a)



(a) Sans afficher les outliers

(b) Outliers par Isolation forest

FIGURE 7 – Réduction de dimension par PCA avec les variables sélectionnées avec *Multiview*

On obtient comme résultats :

Variance expliquée par PC1 : 33.79%

Variance expliquée par PC2 : 25.40%

Variance totale : 59.20%

La variance totale indique que plus de la moitié de l'information des données initiales est conservée dans cette projection, elle reste plus basse que celle de l'ACP appliquée à toutes les variables sans le filtrage, qui était de 63.74%, ce qui est cohérent. Mais on trouve une meilleure variance expliquée selon la deuxième composante. (Figure 7)

La Figure 7b montre graphiquement une bonne séparation entre les deux classes, bien que les variances expliquées ne se sont pas révélées suffisamment convaincantes. Le regroupement est autant plus

marquante lorsque nous appliquons l'algorithme *Isolation forest* sur chacune des deux classes individuellement, afin de detecter les outliers eventuels.

Nous appliquons l'algorithme *Sparse PCA* pour évaluer les variables les plus pertinentes afin de comparer avec celles obtenues avec la méthode de *Multiview*.




FIGURE 8 – Variables les plus contributives par composante

Les variables extraites selon la première composante représentent pour la plupart d'entre elles des caractéristiques sur le nuance de gris et la texture. Tandis que celles retenues par la deuxième composante caractérisent les formes. Les résultats montrent qu'il n'y a aucune variable en commun avec celles les plus importantes par Multiview.

3.3 Random Forest

Il était nécessaire, pour compléter notre analyse, de comparer la méthode multiview à une autre approche de classification. Nous avons ainsi choisi d'opter pour une méthode basée sur les forêts aléatoires (random forest). Cette approche nous a paru particulièrement pertinente, car elle reproduit assez fidèlement la démarche du diagnostic médical réel, où les données observées sont fréquemment comparées à des données de référence à travers des processus décisionnels structurés.

3.3.1 Traitement des données

Afin de permettre une comparaison valide entre les deux méthodes, nous avons appliqué un traitement des données similaire à celui utilisé pour l'approche multiview. La seule différence notable est l'absence de normalisation des données dans le cas de la forêt aléatoire, cette étape n'étant pas requise pour ce type de modèle et pouvant même introduire un biais inutile.

3.3.2 Démarche

Pour évaluer l'impact du déséquilibre entre les classes (CCK et CHC), nous avons entraîné simultanément deux modèles de forêts aléatoires sur 100 graines (seeds) différentes. Le premier modèle ne corrige pas le déséquilibre de classes, tandis que le second tente de compenser cet écart en pondérant davantage les choix liés aux CCK lors de la construction des arbres de décision.

3.3.3 Résultat

TABLE 1 – Résumé des performances des modèles Random Forest

Modèle	Acc.		Bal. Acc.		F1 Macro	
	Moyenne	Écart-type	Moyenne	Écart-type	Moyenne	Écart-type
RF_bal	0.643	0.081	0.646	0.095	0.579	0.077
RF_std	0.821	0.042	0.601	0.082	0.609	0.113

On observe ici que le modèle Random Forest standard (**RF_std**) atteint une précision globale moyenne élevée (accuracy = 0.821), avec une faible variabilité, ce qui témoigne de performances globalement robustes. Cependant, cette performance s'accompagne d'une balanced accuracy plus faible (0.601), révélant une difficulté à bien traiter les classes minoritaires, notamment les tumeurs de type CCK. À l'inverse, le modèle équilibré (**RF_bal**), conçu pour compenser ce déséquilibre, affiche une accuracy plus modeste (0.643), mais parvient à maintenir une balanced accuracy légèrement supérieure (0.646), indiquant une meilleure capacité à gérer l'asymétrie des classes.

Ces résultats traduisent un compromis classique en classification supervisée : favoriser l'équilibre entre classes peut conduire à une perte de performance globale, mais améliore la prise en compte des cas rares, ce qui peut s'avérer crucial en contexte médical.




FIGURE 9 – Histogramme des données les plus explicatives

L'analyse menée à l'aide des modèles Random Forest vient conforter les observations issues de l'approche multiview. En particulier, les variables les plus discriminantes identifiées dans les arbres de décision recoupent celles mises en évidence par l'analyse des composantes explicatives, telles que la sphéricité en phase portale ou les différences entre phases. Cette convergence entre méthodes confère une robustesse supplémentaire à nos résultats et renforce l'idée que certaines caractéristiques morphologiques et dynamiques sont fortement liées à la nature histologique des tumeurs.

4 Conclusion

Ainsi, au vu de notre analyse, la méthode la plus performante est Multiview. Elle possède des métriques plutôt performantes de manière globale, et ces paramètres d'importance semble refléter la réalité clinique des cancers du foie.

De plus, on a pu déterminer les paramètres les plus importants ;

- Variation de l'entropie entre les phases portale et veineuse.
- Evolution des niveaux de gris entre les phases portale et veineuse.
- Sphéricité/forme de la tumeur à la phase portale.