

Rapport Final : Synchronisation de vidéos avec audio et estimation de pose humaine

Pôle Intelligence Artificielle

Équipe 7

André Medeiros
Victor Gueudelot
Loïc Perthuis
Victor Roussel

Encadrant·e·s

Wassila Ouerdane
Jean-Philippe Poli
Mejed El Jabri
Rayane Bouaita

June 8, 2026

Table des matières

1	Introduction	2
1.1	Clients et entreprise	2
1.2	Contexte	2
1.3	Problème posé et bénéfice	2
2	État de l'Art	3
2.1	VideoSync	3
2.2	Synchformer	4
2.3	SeSyn-Net	5
3	Description du travail réalisé	7
3.1	Répartition des tâches	7
3.2	Dataset	8
3.2.1	Étude Préliminaire	8
3.2.2	Critères de Sélection	8
3.2.3	Jeux de Données Filtrés	9
3.2.4	Choix final	10
3.3	Travaux réalisés sur Synchformer	11
3.3.1	Mise en place et prototypage sur les datasets du papier	11
3.3.2	Fine-tuning sur Ego-Exo4D	11
3.3.3	Évaluation	11
3.4	VideoSync	14
3.4.1	Déploiement sur cluster	14
3.4.2	Essai sur CMU	14
3.4.3	Essai sur NTU	15
3.4.4	Résultats	15
3.5	Modélisation, Évaluation et Performances de SeSyn-Net	16
3.5.1	Pipeline algorithmique et robustesse	16
3.5.2	Analyse quantitative sur le Dataset Ego-Exo4D	16
3.5.3	Discussion et comparaison fonctionnelle	17
4	Conclusion et Perspectives	19
4.1	Amélioration des modèles	19
4.2	Pipeline de combinaison des modèles	19
4.3	Prise de recul sur le projet	19
5	Bibliographie	21

1 Introduction

1.1 Clients et entreprise

Ce projet a été mené en étroite collaboration avec l'entreprise **GoPro**, mondialement connue pour la manufacture de *caméras d'action* ainsi que le développement de logiciels. Plus particulièrement nous travaillons dans le cadre de l'application mobile **GoPro Quik** qui permet de faire des montages vidéos et photos sur téléphone.

Au sein de GoPro, nos interlocuteurs sont *Mejed El Jabri* qui est **Principal Data Scientist** chez GoPro, ainsi que *Rayane Bouaita* ingénieur en Computer Vision.

1.2 Contexte

Pour comprendre la valeur ajoutée de notre contribution à l'application *GoPro Quik*, il convient d'analyser une situation fréquente : une même scène (généralement sportive) est filmée simultanément à l'aide de plusieurs caméras sous des angles différents. Ces flux vidéo présentent souvent un décalage temporel initial, et l'objectif est d'obtenir une séquence unique et harmonisée combinant les différents points de vue avec un décalage temporel minimal.

Cependant, en l'absence de référentiel temporel commun ou de signal de synchronisation partagé entre les appareils, un alignement direct est impossible. Il est donc nécessaire de concevoir des algorithmes élaborés capables de s'appuyer sur le contenu intrinsèque des flux pour recréer ce lien temporel.

Ainsi, notre objectif est de proposer un pipeline robuste intégrant plusieurs modèles de Deep Learning dédiés à la résolution automatique de ce problème d'alignement. Dans cette optique, nous avons réalisé un état de l'art approfondi afin d'isoler trois architectures distinctes et complémentaires, offrant ainsi une solution technique directement exploitable et bénéfique pour le client.

1.3 Problème posé et bénéfice

Le problème principal abordé dans ce projet est la difficulté de synchroniser une même scène enregistrée simultanément par plusieurs caméras sous différents angles. Dans un contexte sportif et non contraint, les solutions traditionnelles fondées uniquement sur l'audio s'avèrent souvent inefficaces, et l'absence de référentiel temporel commun empêche tout alignement direct des flux vidéo.

Le bénéfice de notre approche est d'offrir à GoPro un pipeline d'Intelligence Artificielle robuste intégrant l'utilisation conjointe de plusieurs modèles complémentaires. En s'appuyant de façon adaptative sur des architectures d'analyse audio-visuelle et d'estimation de pose humaine, telles que *Synchformer*, *VideoSynch* et *SeSyn-Net*, le système permet de surmonter les défaillances de la synchronisation audio classique en l'absence de signal sonore clair ou continu. Cette automatisation garantit un alignement précis et transparent des flux, améliorant ainsi significativement l'expérience des utilisateurs de l'application GoPro Quik lors du traitement de leurs séquences multi-points de vue.

2 État de l'Art

2.1 VideoSync

Contexte : Intuitivement, pour synchroniser deux (ou plus) vidéos qui sont potentiellement décalées temporellement on essaye de faire coïncider les frames les plus proches.

Fonctionnement : C'est de cette idée intuitive que part le modèle *VideoSync* qui procède selon les étapes suivantes :

- On décompose les vidéos image par image
- On calcule les vecteurs d'embedding pour chaque frame (ici le modèle *CARL*)
- On calcule alors la matrice des distances euclidiennes négatives entre paires d'images (similarité)
- Enfin, un classifieur (plusieurs classifieurs sont proposés dans l'article) est utilisé pour prédire le délai de synchronisation




FIGURE 1 – Pipeline de fonctionnement de VideoSync

Avantages :

- Modèle relativement simple par rapport aux autres
- S'utilise dans un large cadre contrairement à d'autres modèles
- Performant selon la littérature

Inconvénients :

- GitHub plus trop maintenu
- Script adapté pour un faible nombre de datasets, ce qui pourrait engendrer des problèmes d'adaptation à d'autres datasets dans le futur
- Grosse dépendance sur le framerate même si on part sur une base 30 fps

2.2 Synchformer

Dans des environnements non contraints (sport, extérieur), les indices de synchronisation sont souvent « épars » (*sparse cues*), c'est-à-dire brefs et isolés. L'objectif, avec ce modèle, est de détecter ces moments critiques pour aligner l'audio et la vidéo sans dépendre d'un flux continu comme la parole.

Fonctionnement : Le modèle repose sur une architecture Transformer hybride qui traite les données de la manière suivante :

- **Extraction segmentée :** Le flux vidéo (frames RGB) et le flux audio (spectrogramme Mel) sont découpés en segments courts de 0,64 s, puis encodés séparément par des réseaux profonds dédiés — Motionformer avec attention spatio-temporelle divisée pour la vidéo, et AST (*Audio Spectrogram Transformer*) pour l'audio.
- **Agrégation :** Les représentations de chaque segment sont compressées le long de la dimension spatiale (ou fréquentielle) par un encodeur Transformer mono-couche, produisant un vecteur par segment et par modalité.
- **Attention multi-modale :** Un module de synchronisation léger (Transformer 3 couches, 8 têtes, $d = 768$) fusionne la séquence des représentations audio et vidéo de tous les segments, augmentée de tokens auxiliaires [CLS] et [SEP], pour prédire le décalage temporel.
- **Classification :** La prédiction est formulée comme une classification sur 21 classes couvrant l'intervalle $[-2,0 \text{ s}; +2,0 \text{ s}]$ par pas de 0,2 s.

Entraînement en deux phases : Les extracteurs de caractéristiques sont d'abord pré-entraînés par apprentissage contrastif au niveau du segment (*Segment AVCLIP*), avec une perte InfoNCE rapprochant les représentations de segments contemporains. Dans un second temps, les poids des extracteurs sont gelés et seul le module de synchronisation est entraîné, ce qui permet d'utiliser des extracteurs beaucoup plus grands (214 M de paramètres) tout en maintenant un coût d'entraînement raisonnable.




FIGURE 2 – Architecture de Synchformer (Iashin et al., ICASSP 2024)

Avantages :

- État de l'art en termes de précision sur les jeux de données réels (*in-the-wild*).
- Capacité à synchroniser via des indices rares (chocs, bruits d'ambiance) sans présence humaine nécessaire.
- Architecture modulaire permettant d'interchanger les extracteurs de caractéristiques selon les besoins.

- Score de confiance intégré, exploitable comme signal de qualité de la prédiction.

Inconvénients :

- Coût computationnel élevé, notamment pour la première phase d'entraînement.
- Performances dégradées sur les activités à signal audio-visuel continu (musique, danse).
- Nécessite un pré-encodage des vidéos (framerate, résolution, fréquence audio) pour garantir la compatibilité avec le pipeline d'inférence.

2.3 SeSyn-Net

Contexte : SeSyn-Net introduit un cadre d'apprentissage auto-supervisé (*self-supervised*) centré sur l'humain pour la synchronisation automatique de vidéos multi-caméras. L'approche repose sur l'idée que les poses humaines 2D constituent une information invariante par rapport au point de vue (*view-invariant*) mais hautement discriminante dans le temps, permettant ainsi l'alignement de flux vidéos sans nécessiter d'indices visuels externes ou de calibration complexe des caméras.

Fonctionnement : Le modèle extrait et compare les dynamiques de mouvement à travers les étapes suivantes :

- **Extraction Pose-centrique :** Les coordonnées des articulations 2D et leurs scores de confiance sont extraits pour chaque trame via le réseau **HRNet**.
- **Architecture ST-GCN modifiée :** Le modèle utilise un réseau **ST-GCN** (*Spatio-Temporal Graph Convolutional Network*) comme extracteur de caractéristiques. Pour garantir une représentation précise au niveau de la trame (*frame-level*), les foulées temporelles (*strides*) des couches de convolution sont réduites à 1, évitant ainsi la perte de résolution temporelle.
- **Apprentissage par Pertes Auto-supervisées :** Trois fonctions de perte garantissent la robustesse du modèle sans annotation manuelle :
 - **Identity Loss** ($\mathcal{L}_{iden} = -\sum_{m=1}^M y_m \log \hat{y}_m$) : Impose une cohérence cyclique entre les vues pour s'assurer qu'une trame dans une vidéo correspond de manière unique à une trame dans l'autre.
 - **Deviation Loss** ($\mathcal{L}_{devi} = \frac{1}{M} \sum_{m=1}^M |p_m - g_m|$) : Contraint la linéarité en minimisant l'écart entre l'indice de trame original g et l'indice prédit p après un cycle de correspondance.
 - **Interval-consistency Loss** ($\mathcal{L}_{intv} = \frac{1}{M-1} \sum_{m=2}^M |p_m - p_{m-1} - 1|$) : Assure la continuité temporelle en forçant les trames prédites successives à maintenir un intervalle régulier.
- **Estimation de l'Offset :** Une matrice de corrélation est générée à partir de la distance euclidienne des *embeddings*. Le décalage temporel final Δt est calculé par la **médiane** des décalages prédits sur l'ensemble des paires de trames, ce qui filtre efficacement les bruits d'estimation locaux.




FIGURE 3 – Illustration de la pose humaine sous deux perspectives différentes, indiquées respectivement par les encadrés orange et bleu.




FIGURE 4 – Architecture globale de la méthode proposée. À partir de deux vidéos issues de caméras différentes, les poses de la personne sont d’abord obtenues via un réseau d’estimation de pose, puis les caractéristiques de chaque trame sont extraites par un réseau d’encodage (*feature embedding*). Enfin, trois pertes auto-supervisées sont construites à partir de ces caractéristiques pour entraîner le réseau de synchronisation, où m et n représentent les caractéristiques des m -ième et n -ième trames des deux vidéos, et τ représente l’intervalle entre les trames.

3 Description du travail réalisé

3.1 Répartition des tâches

Activité	Tâche	Responsable	Équipe impliquée
1	Acquisition des datasets	André	-
	Préparation des environnements	Victor R.	Victor G., Loïc
2	Analyse statistique des données	André	-
	Validation des baselines (reproductibilité)	Victor R.	Victor G., Loïc
3	Adaptation & Analyse de compatibilité	Victor G.	Loïc, André
	Évaluation isolée de <i>Synchformer</i>	Victor R.	-
4	Optimisation (fine-tuning) et SED	Victor G.	Loïc, André
	Validation croisée sur datasets cibles	Victor R.	-
5	Finalisation et packaging des livrables	Collectif	Toute l'équipe

TABLE 1 – Lots de travail.

3.2 Dataset

Le choix des datasets pour le projet a été divisé en trois étapes méthodologiques : une étude préliminaire, la définition des critères de sélection et un filtrage final adaptatif.

3.2.1 Étude Préliminaire

Dans un premier temps, nous avons mené une recherche approfondie afin de recenser les bases de données disponibles dans la littérature et pertinentes pour le cadre de ce projet. La Table 2 présente les datasets qui ont été trouvés lors de la première étape.

Datasets	Format	Multi-vues	Accès	Annotations
Ego-Exo4D	Audio et vidéo	Oui	Demandé	Squelettes 3D et points clés (corps, visage, main), nuages de points
CMU Panoptic	Vidéo	Oui	Ouvert	Squelettes 3D et points clés (corps, visage, main)
Human3.6M	Vidéo	Oui	Demandé	Squelettes 3D et points clés (corps, visage, main)
NTU RGB+D 120	Vidéo	Oui	Demandé	Squelettes 3D et points clés (corps, visage, main), données IR
AMI Meeting	Audio et vidéo	Oui	Ouvert	Ordre du jour de la réunion
STARSS23	Vidéo	Oui	Ouvert	Événements sonores
CVID	Vidéo	Oui	Ouvert	Boîtes englobantes 2D
Kinetics-700	Audio	Non	Ouvert	Étiquettes d'action

TABLE 2 – Les datasets identifiés lors de la première étape.

L’analyse préliminaire a porté sur huit ensembles principaux : Ego-Exo4D [5], CMU Panoptic [6], Human3.6M [7], NTU RGB+D 120 [8], AMI Meeting [9], STARSS23 [10], CVID [11] et Kinetics-700 [12]. Pour chacun d’entre eux, nous avons cartographié les caractéristiques fondamentales telles que le format des fichiers (présence d’audio et de vidéo), la prise en charge de vues multi-caméras, la facilité d’accès (libre ou sur demande) et le niveau d’annotation disponible.

3.2.2 Critères de Sélection

La deuxième étape a consisté à établir les paramètres idéaux qu’un dataset devrait posséder pour répondre à notre scénario. Les critères généraux définis ont été les suivants :

- **Format multisensoriel** : Données contenant simultanément de l’audio et de la vidéo, capturées sous de multiples angles.

- **Annotations de pose :** Disponibilité de marquages de pose détaillés, plus précisément des squelettes 3D humains.
- **Polyvalence de manipulation :** Possibilité de télécharger le jeu de données de manière fractionnée (petits échantillons), afin de permettre un traitement local et de contourner les éventuelles contraintes de stockage.
- **Accessibilité :** Facilité d’obtention et d’accès aux données brutes de la base.

Lors de l’application de ces critères, nous avons constaté qu’il n’existait aucun dataset parfait qui puisse satisfaire intégralement toutes les exigences pour l’ensemble des modèles. Afin de contourner cette limitation, nous avons procédé à une analyse individuelle de chaque dataset, en tenant compte des besoins et des spécificités de chaque modèle, ce qui a rendu la méthode de sélection plus flexible.

3.2.3 Jeux de Données Filtrés

À l’issue de cette démarche, la troisième étape a abouti à l’application des filtres et à la sélection finale de quatre datasets, conformément à la Table 3.

Dataset	Format	Multi-vues	Annotations	Taille (To)	Durée (h)
Ego-Exo4D	Audio et vidéo	Oui	Squelettes 3D et points clés (corps, visage, main), nuages de points, données de référence	38	1 286
NTU RGB+D 120	Vidéo	Oui	Squelettes 3D et points clés (corps, visage, main), cartes de profondeur, données IR	4	6
CMU Panoptic	Vidéo	Oui	Squelettes 3D et points clés (corps, visage, main)	5	11
Kinetics-700	Audio	Non	Étiquettes d’action	< 1	650

TABLE 3 – Les datasets identifiés lors de la première étape..

Les quatre datasets sélectionnés offrent des approches complémentaires pour le projet, variant en termes d’échelle, d’environnement de capture et de type d’annotation. Ego-Exo4D se distingue comme le plus complet et le plus volumineux, avec 38 To et 1 286 heures de données multimodales (audio et vidéo multi-vues avec squelettes 3D) capturées par des appareils portables et des caméras fixes. En revanche, NTU RGB+D 120 et CMU Panoptic sont nettement plus courts en durée et axés sur des environnements plus contrôlés, fournissant des données précises de reconstruction corporelle pour les actions quotidiennes et les interactions sociales. Le Kinetics-700, dont l’approche diffère de celle des trois autres datasets, présente des enregistrements hétérogènes de courte durée extraits de YouTube.

3.2.4 Choix final

Dans le but de comparer les différents modèles sur le même dataset, nous avons choisi de continuer l'étude avec Ego-Exo4D. En effet, ce dernier intègre simultanément de l'audio, de la vidéo et des annotations de squelettes 3D, se rapprochant ainsi le plus des critères de sélection du dataset idéal que nous avons formulés.

3.3 Travaux réalisés sur Synchformer

3.3.1 Mise en place et prototypage sur les datasets du papier

La première étape a consisté à déployer Synchformer sur le cluster de calcul GPU de CentraleSupélec (DGX A100, soumission via SLURM). Le code source officiel des auteurs a été récupéré et adapté à l’infrastructure : configuration de l’environnement Conda, gestion des dépendances CUDA, et écriture de scripts de soumission permettant de gérer les partitions MIG disponibles (3g.40gb et plus modestes).

Plusieurs obstacles techniques ont dû être surmontés à ce stade, notamment des erreurs récurrentes d’*Out-Of-Memory* (OOM) sur la RAM système lors de l’inférence sur des vidéos HD, dues au chargement intégral des frames en mémoire. La solution a consisté à pré-encoder systématiquement les vidéos au format attendu par le modèle (25 fps, 256 px de côté, audio 16 kHz) et à découper les vidéos longues en segments de 10 secondes traités par des jobs SLURM indépendants.

Une première validation a été conduite sur des extraits du dataset STARSS23 et du CMU Panoptic, avec des décalages imposés *a priori*, afin de confirmer le bon fonctionnement du pipeline d’inférence et d’apprendre à interpréter les sorties du modèle (distribution de probabilité sur 21 classes d’offset, score de confiance associé).

3.3.2 Fine-tuning sur Ego-Exo4D

Le dataset Ego-Exo4D a été retenu comme support principal pour le fine-tuning : il combine caméras GoPro exocentriques et caméras Aria Glass égocentriques dans des conditions réelles variées (cuisine, sport, activités médicales), ce qui correspond directement au cas d’usage GoPro Quik.

Le fine-tuning porte exclusivement sur la **Phase II** de l’entraînement décrit dans le papier, c’est-à-dire le module de synchronisation léger, les poids des extracteurs de caractéristiques AST et Motionformer étant maintenus gelés. Le modèle de départ est le checkpoint AudioSet pré-entraîné par les auteurs. Les vidéos d’entraînement ont été découpées en segments de 10 secondes, donnant un corpus d’environ 7 000 segments après filtrage. L’entraînement a duré approximativement 20 heures sur partition prod40 (MIG 3g.40gb).

3.3.3 Évaluation

L’évaluation a porté sur le sous-ensemble **body-test** d’Ego-Exo4D, soit 213 takes couvrant 13 classes d’activité. Pour chaque take, un offset aléatoire dans $[-2,0\text{ s}; +2,0\text{ s}]$ est appliqué entre le flux vidéo (cam01) et le flux audio (aria01.wav). Le modèle est appliqué sur des fenêtres glissantes de 10 secondes, et deux stratégies d’agrégation des prédictions segment par segment sont comparées :

- **Best Confidence (BC)** : on retient la prédiction du segment ayant le score de confiance le plus élevé.
- **Weighted Average (WA)** : la prédiction finale est la moyenne pondérée par les confiances de toutes les prédictions de segments.

Performances globales. La stratégie Best Confidence obtient une MAE de **0,487 s**, significativement meilleure que la stratégie Weighted Average (MAE = 0,583 s). Diluer les segments peu informatifs dans la moyenne dégrade donc la prédiction (voir Figure 5).




FIGURE 5 – Comparaison des MAE globales des deux stratégies d’agrégation.

Analyse par classe d’activité. Les performances sont fortement corrélées à la nature des indices audio-visuels (Figure 6). Les activités continues (musique, danse, football) donnent une MAE entre 1,00 et 1,80 s, alors que les activités à événements discrets (cooking, pcr, cpr, omelet, salad, sushi) atteignent des MAE proches ou égales à 0, le modèle retrouvant l’offset à la précision de la grille de classification (0,2 s). Ainsi, le modèle pourrait être très adapté au vidéo de sport où au moins une piste audio capture un évènement discret bien distinct.




FIGURE 6 – MAE par classe d’activité, comparaison Best Confidence vs Weighted Average.

Calibration du score de confiance. La confiance produite par le modèle est fortement corrélée à la précision réelle (Tableau 4). Il est important de noter que ce score de confiance est une sortie intrinsèque du modèle — la probabilité maximale issue du softmax de la couche de classification — et non une métrique calculée *a posteriori* sur les résultats. Il constitue donc un signal de routage directement exploitable en production pour basculer vers une méthode alternative (SeSyn-Net) en cas de faible confiance.

Palier de confiance	MAE	Population
$> 0,8$	0,115 s	115 takes (54 %)
$0,5 - 0,8$	0,759 s	58 takes (27 %)
$< 0,5$	1,165 s	40 takes (19 %)

TABLE 4 – MAE par palier de confiance (stratégie Best Confidence).

Enfin, en combinant les deux filtres les plus favorables — activités à indices discrets et confiance $> 0,8$ — on isole une sous-population de 89 takes sur laquelle le modèle atteint une **MAE de 0,081 s**, soit en dessous du pas de discrétisation de la grille. Ce résultat valide l’adéquation de Synchformer pour le cœur de cible de GoPro Quik : sports avec impacts et activités manuelles précises.

3.4 VideoSync

Nous sommes tombés sur ce modèle lors de notre état de l’art, et des notes ont été prises à chaque séance histoire de faciliter le déploiement de cette solution. Ainsi nous pouvons retracer l’ensemble du parcours mené pour arriver à ces résultats. Cette partie du projet a été globalement menée par Victor Gueudelot avec parfois de l’aide notamment de Andre Felipe de Medeiros pour adapter rapidement à un nouveau dataset.

3.4.1 Déploiement sur cluster

La première étape consistait à mettre en place le code trouvé sur GitHub sur la DGX. Dès le début, et tout au long du projet, nous avons fait face à plusieurs obstacles en partie dus au GitHub qui n’était pas maintenu ce qui a causé plusieurs problèmes techniques. Le premier était un problème avec l’environnement Python et nous avons choisi de créer un venv personnalisé en s’éloignant du github pour être sûr qu’il fonctionnait, notamment wandb qui avait causé beaucoup de problèmes pour lancer les batch.

3.4.2 Essai sur CMU

Pour les premiers tests du programme nous avons décidé de nous tourner vers le dataset CMU pour deux raisons principales : son utilisation par le modèle était référencée sur le repo et le dataset CMU est de taille relativement faible par rapport aux autres donc il était utilisable sur l’espace très réduit de la DGX et était relativement rapide pour des premiers tests. Il fallait ensuite lancer le téléchargement des vidéos le pre-process, nous avons également pris un peu de temps car nous voulions télécharger le dataset en local et vérifier que son utilisation était logique dans notre projet. Cette étape nous a alors pris une semaine.

La prochaine étape était l’entraînement de CMU, ce qui a été une étape fastidieuse pour plusieurs raisons techniques simples mais difficiles à identifier parmi lesquelles :

- Certains dossier, fichiers qui étaient attendus à l’étape $n+1$ du programme n’étaient pas créés à l’étape n
- L’architecture des dossiers n’était pas très claire dans le repo elle a donc été retravaillée pour être la plus simple possible et compatible avec n’importe quel dataset
- Certains paths étaient hardcodés de façon conflictuelle
- Certains bouts de code ne tournaient tout simplement pas

C’est pour ces raisons que faire tourner l’entraînement a pris un peu plus d’un mois mais ces débuts étaient nécessaires et ont beaucoup aidé à simplifier le processus pour faire tourner sur d’autres datasets. Cela a également permis de mieux comprendre la structure du code.

Il restait ensuite l’étape d’évaluation où l’on construisait la matrice de dissimilarité pour chaque paire de vidéos. Ces étapes ont également pris un peu de temps à déboguer pour des problèmes similaires à avant mais le code a fini par tourner au bout de deux semaines.

3.4.3 Essai sur NTU

Une fois que le code marchait sur le CMU nous avons décidés de tenter de faire tourner l'algorithme sur le dataset NTU, beaucoup plus complet. Cependant, nous étions au courant que le modèle avec le dataset NTU complet ne pouvait pas tourner sur la DGX, nous avons donc à la suite de discussions avec GoPro décidés que nous pouvions tenter de faire tourner le script sur une partie minuscule de NTU (5%) pour que GoPro puisse faire tourner le script sur leur cluster.

Des problèmes similaires aux problèmes obtenus pour le CMU sont apparus mais grâce à l'expérience gagnée et aux debugging déjà effectués, l'entiereté de l'implémentation a pris un peu moins de 2 semaines. Nous avons même pu à la fin refaire tourner le script de A à Z pour vérifier que le livrable que nous allions proposer serait clé en main pour le client.

3.4.4 Résultats

Nous avons effectué des tests avec 4 classifieurs : SVM, MLP, CNN et LogReg. Les vidéos de bases étaient décalées de ± 30 frames (± 1 seconde pour des vidéos à 30 fps) et l'algorithme renvoyait une prédiction de cet offset. Les résultats sont les suivants :

	SVM	CNN	MLP	LogReg	Baseline
CMU Dataset	9,4	9,6	9,7	10	9,5
NTU (5%)	14,2	16,4	18,8	19,1	14,3

TABLE 5 – Comparaison des offset en frame pour 4 types de classifieurs et pour deux datasets

Interprétation : Il est déjà important de noter que vu la faible taille des datasets le décalage moyen varie grandement à chaque fois qu'on applique un décalage aléatoire, ainsi les variations entre les deux datasets ne sont pas représentatives ici. On s'intéresse plutôt aux variations au sein d'une même ligne. On peut tirer plusieurs constats : déjà le SVM semble être le meilleur classifieur même s'il progresse moins sur un grand nombre d'epochs ; deuxièmement on semble observer que les modèles sont très proches (voir éloignés) d'une performance aléatoire ce qui n'est pas très rassurant.

Cependant, lorsqu'on regarde en pratique comment le modèle performe cela devient beaucoup plus compréhensible. En effet, quand on voit les vidéos sur lesquelles le modèle performe de façon excellente (prédit parfaitement l'offset) on remarque une vidéo dans laquelle on distingue clairement les mouvements ce qui est cohérent avec l'idée de l'algorithme. A l'inverse, la paire vidéos sur laquelle il se trompe parfaitement sont des vidéos quasi statiques donc dur à distinguer à vue d'oeil. L'utilisation de ce modèle avec un dataset complet semble alors une piste prometteuse !

3.5 Modélisation, Évaluation et Performances de SeSyn-Net

Dans le cadre de nos expérimentations pour le compte de **GoPro Quik**, le modèle *SeSyn-Net* a été configuré et évalué pour répondre au défi de la synchronisation multi-vues dans des scénarios sportifs complexes. L'intérêt principal de cette architecture repose sur son insensibilité aux variations d'apparence globale grâce à l'extraction exclusive des poses humaines en 2D.

3.5.1 Pipeline algorithmique et robustesse

Le traitement des données s'effectue en deux temps. Tout d'abord, les vidéos brutes subissent un pré-traitement via le réseau HRNet pour générer les tenseurs de coordonnées de squelettes. Ces fichiers structurés sont ensuite injectés dans le réseau d'encodage **ST-GCN** modifié (sans réduction de résolution temporelle). L'alignement temporel final s'appuie sur la propriété statistique suivante :

Théorème 3.1: Robustesse de l'estimateur médian

Soit $\mathcal{D} = \{\delta t_1, \delta t_2, \dots, \delta t_M\}$ l'ensemble des décalages temporels locaux calculés par appariement cyclique sur M paires de trames. Si la proportion d'erreurs de prédiction locales (occlusions temporaires, faux positifs d'extraction de pose) est strictement inférieure à 50%, alors l'estimateur du décalage global défini par :

$$\Delta t = \text{médiane}(\mathcal{D}) \quad (1)$$

converge vers la valeur réelle du décalage temporel entre les deux caméras, indépendamment de la magnitude des anomalies locales.

Preuve 3.1

La médiane possède un point de rupture empirique de 0,5. Contrairement à une moyenne arithmétique qui propage l'erreur d'un vecteur d'embedding corrompu (par exemple lors d'une occlusion par un équipement sportif ou une sortie de champ partielle), l'opérateur de tri rejette les valeurs aberrantes aux extrémités de la distribution $\mathcal{D}$, isolant ainsi le décalage géométrique majoritaire induit par la désynchronisation des flux.

3.5.2 Analyse quantitative sur le Dataset Ego-Exo4D

Afin de valider la viabilité opérationnelle de l'algorithme, nous avons mené une campagne de tests approfondie sur le jeu de données **Ego-Exo4D**, caractérisé par ses prises de vues égocentriques (première personne) et exocentriques (caméras tierces) hautement non contraintes.

La figure 7 synthétise la fonction de répartition cumulative de l'erreur absolue d'alignement temporel obtenue sur ce benchmark.

L'analyse de ces résultats métriques met en lumière des propriétés remarquables :

- 1 **Précision à la trame près** : Environ **20,1%** des paires de séquences vidéo atteignent une synchronisation quasi parfaite avec une erreur inférieure ou égale




FIGURE 7 – Performance cumulative de SeSyn-Net sur Ego-Exo4D : proportion de vidéos alignées en fonction de la tolérance à l’erreur (en secondes).

à 0,03 seconde (soit l’équivalent d’une seule trame à un framerate standard de 30 FPS).

- 2 **Convergence sous la seconde : 60,3%** des vidéos montrent un décalage résiduel strictement inférieur à 0,33 seconde. De manière cruciale, **100%** de notre échantillon de test se stabilise sous la barre de la seconde (1,00 s).

3.5.3 Discussion et comparaison fonctionnelle

Ces résultats démontrent l’excellente complémentarité de SeSyn-Net vis-à-vis d’autres modèles de l’état de l’art étudiés dans ce rapport :

Critère	Synchformer (Audio-Visuel)	SeSyn-Net (Pose-Centrique)
Signal requis	Flux audio continu / Événements sonores	Visibilité de la silhouette humaine (2D)
Sensibilité au point de vue	Élevée (dépend de la texture pixel)	Quasi nulle (représentation invariante)
Performance en sport extrême	Faible si bruit de vent / saturation audio	Excellente si le sujet est cadré
Garantie sur Ego-Exo4D	Erreurs dues aux bruits ambiants	Convergence à 100% sous la seconde

TABLE 6 – Tableau comparatif des dépendances et performances de synchronisation.

- **Points forts validés** : Le modèle extrait des structures géométriques robustes face au vent, aux projections ou aux distorsions acoustiques inhérentes aux caméras GoPro en action. L’absence de signal sonore n’altère en rien la précision de l’alignement.
- **Limitations techniques** : L’architecture est dépendante de la qualité d’extraction du squelette en amont. Si le sujet est trop éloigné (taille inférieure à quelques

pixels) ou si l'occlusion par un élément du décor dure plus longtemps que la fenêtre temporelle T , la matrice de corrélation se fragmente, réduisant localement la précision.


4 Conclusion et Perspectives

4.1 Amélioration des modèles

Pour le modèle VideoSync, il est évident que ses performances peuvent être améliorées en utilisant totalement le dataset NTU. De manière générale, chaque modèle pourrait être spécialisé par fine-tuning sur des jeux de données correspondant à ses conditions de performance optimales, puis intégré dans une pipeline de routage plus large. Par exemple, Synchformer pourrait être entraîné exclusivement sur des données sportives présentant des événements sonores marqués (impacts, chocs), domaine sur lequel il excelle déjà, tandis que SeSyn-Net prendrait le relais sur les scènes à signal audio faible mais à présence humaine visible.

4.2 Pipeline de combinaison des modèles

En plus d'améliorer les différents modèles, on pourrait également envisager de les combiner pour avoir une pipeline robuste, fonctionnelle sur un large panel de vidéos. En effet, alors que Synchformer devient très performant lorsqu'il a accès à un audio sur lequel il est relativement confiant, il l'est beaucoup moins le reste du temps et on pourrait alors utiliser SeSyn-Net qui n'a même pas besoin de l'audio. Dans cette pipeline nous n'avons pas pris en compte le modèle VideoSync car il sous-performait par la faiblesse d'entraînement mais il serait possible de l'intégrer dans la pipeline dans le futur.



4.3 Prise de recul sur le projet

Ce projet a été une opportunité de travailler sur un problème de recherche ouvert, avec des données complexes (vidéo multi-vues, audio bruité, poses humaines) et un client industriel aux contraintes de production réelles. Aucun des modèles évalués ne résout

à lui seul le problème dans toutes les conditions, mais le benchmark comparatif que nous avons produit fournit au client une base factuelle pour orienter ses futurs développements : quels modèles privilégier, dans quelles conditions, et avec quels indicateurs de fiabilité.

Sur le plan technique, le projet nous a confrontés à des difficultés absentes d'un cadre purement académique : gestion de datasets volumineux sur cluster partagé, débogage d'erreurs mémoire sur GPU, adaptation de code de recherche à une infrastructure différente. Ces compétences en ingénierie ML sont celles qui nous ont le plus fait progresser. Enfin, le dialogue avec GoPro nous a appris à formuler nos résultats en termes de valeur d'usage plutôt qu'en métriques académiques seules, un réflexe que nous retenons pour la suite.

5 Bibliographie

Références

- [1] L. YIN, R. HAN, W. FENG et S. WANG, “Self-Supervised Human Pose based Multi-Camera Video Synchronization,” in *Proceedings of the 30th ACM International Conference on Multimedia*, sér. MM '22, Lisboa, Portugal : Association for Computing Machinery, 2022, p. 1739-1748, ISBN : 9781450392037. DOI : 10.1145/3503161.3547766 adresse : <https://doi.org/10.1145/3503161.3547766>
- [2] Y. SHIN et I. MOLYBOG, *Beyond Audio and Pose : A General-Purpose Framework for Video Synchronization*, 2025. arXiv : 2506.15937 [cs.CV]. adresse : <https://arxiv.org/abs/2506.15937>
- [3] V. IASHIN, W. XIE, E. RAHTU et A. ZISSERMAN, “Synchformer : Efficient Synchronization From Sparse Cues,” in *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2024, p. 5325-5329. DOI : 10.1109/ICASSP48485.2024.10448489
- [4] J. VOAS et al., “Temporally Streaming Audio-Visual Synchronization for Real-World Videos,” in *2025 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2025, p. 1-9. DOI : 10.1109/WACV61041.2025.00490
- [5] K. GRAUMAN et al., “Ego-Exo4D : Understanding Skilled Human Activity from First- and Third-Person Perspectives,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, IEEE, 2024.
- [6] H. JOO et al., “Panoptic Studio : A Massively Multiview System for Social Motion Capture,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, IEEE, 2015, p. 3334-3342. DOI : 10.1109/ICCV.2015.381
- [7] C. IONESCU, D. PAPAVAL, V. OLARU et C. SMINCHISESCU, “Human3.6M : Large Scale Datasets and Predictive Methods for 3D Human Sensing in Natural Environments,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, t. 36, n° 7, p. 1325-1339, 2014. DOI : 10.1109/TPAMI.2013.248
- [8] J. LIU, A. SHAHROUDY, M. PEREZ, G. WANG, L.-Y. DUAN et A. C. KOT, “NTU RGB+D 120 : A Large-Scale Benchmark for 3D Human Activity Understanding,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, t. 42, n° 10, p. 2684-2701, 2019. DOI : 10.1109/TPAMI.2019.2916873
- [9] J. CARLETTA et al., “The AMI Meeting Corpus : A Pre-announcement,” in *Machine Learning for Multimodal Interaction (MLMI)*, Springer, 2005, p. 28-39.
- [10] A. POLITIS et al., “STARSS23 : An Audio-Visual Dataset of Spatial Recordings of Real Scenes with Spatiotemporal Annotations of Sound Events,” in *Proceedings of the Detection and Classification of Acoustic Scenes and Events (DCASE) Workshop*, 2023.
- [11] J. ZHAO, R. HAN, Y. GAN, W. FENG, L. WAN et S. WANG, “Complementary-View Multiple Human Tracking,” in *ACM International Conference on Multimedia*, 2020.
- [12] J. CARREIRA, E. NOLAND, C. HILLIER et A. ZISSERMAN, *A Short Note on the Kinetics-700 Human Action Dataset*, 2019. arXiv : 1907.06987 [cs.CV]. adresse : <https://arxiv.org/abs/1907.06987>